



UNIVERSIDAD · ECCI

Predicción de fuga de clientes

Integrantes

Laura Alejandra Becerra Feo
Sergio Steban Aguirre Alfonso

Docente

Fredy Alexander Orjuela López

Universidad ECCI
Ingeniería industrial
Sistemas de información gerencial

1. Definición de métricas en el contexto de churn

Las siguientes métricas fueron obtenidas del experimento de Machine Learning y se interpretan desde la óptica de la toma de decisiones gerenciales en una empresa de telecomunicaciones:

Métrica	Definición	Implicación para el negocio
Accuracy	Porcentaje de predicciones correctas sobre el total de casos evaluados.	Un modelo con Accuracy = 0.76 acertó en el 76% de los clientes. Advertencia: un modelo que prediga 'nadie se va' obtendría 73% sin ser útil, pues esa es la proporción base de clientes que no se fugan.
Recall	De todos los clientes que realmente se fugan, ¿cuántos detecta el modelo?	Recall = 0.35 significa que se detectan 35 de cada 100 desertores reales. Es la métrica crítica para no dejar escapar clientes valiosos.
Precision	De todos los clientes marcados como 'fugará', ¿cuántos realmente lo harán?	Precision = 1.00 en CatBoost significa que cada alarma es verdadera, pero el modelo lanza muy pocas (Recall = 0.11), dejando escapar al 89% de los desertores.
F1-Score	Media armónica entre Recall y Precision. Penaliza los extremos desequilibrados.	Un modelo con Precision = 1.00 y Recall = 0.11 obtiene F1 = 0.20, evidenciando que sacrifica demasiado la detección de desertores.
AUC	Área bajo la curva ROC. Mide la capacidad discriminativa del modelo en todos los umbrales posibles.	AUC = 0.50 equivale a adivinar al azar; 1.00 es perfecto. En esta tabla los valores rondan 0.55–0.57, lo que indica capacidad discriminativa modesta con el conjunto de datos sintético.
Kappa / MCC	Corrigen el efecto del desbalance de clases en la evaluación del modelo.	Un modelo que siempre predice 'no fuga' obtiene Accuracy = 0.73 pero Kappa = 0 y MCC = 0, demostrando que no aprendió nada real. Son más confiables que el Accuracy cuando las clases están desbalanceadas.

2. Análisis de costos por tipo de error

La campaña de retención consiste en ofrecer un mes gratis de servicio a cada cliente identificado como 'en riesgo de fuga'. Esto obliga a evaluar dos tipos de error con impactos económicos distintos:

Tipo de error	Descripción	Impacto en el negocio
Falso Positivo (FP)	El modelo predice fuga, pero el cliente se habría quedado.	Se entrega un mes gratis innecesariamente. Costo puntual, recuperable en el siguiente ciclo de facturación.
Falso Negativo (FN)	El modelo no detecta al desertor y no se activa la campaña.	El cliente cancela. Pérdida permanente del Customer Lifetime Value (CLV). Adquirir un nuevo cliente cuesta entre 5 y 7 veces más que retener uno existente.

3. Modelo recomendado para la campaña

Modelo seleccionado: Extra Trees Classifier. Alternativa conservadora: Random Forest.

Justificación estratégica:

- CatBoost, LightGBM y Extreme Gradient Boosting tienen Precision = 1.00 pero Recall = 0.11: detectan menos del 12% de los desertores reales. No son adecuados para campañas de retención masiva.
- Decision Tree registra el mayor Recall (0.3567) pero genera un alto volumen de alertas incorrectas (Kappa = 0.09, F1 = 0.34), lo que implica un gasto elevado en meses gratis innecesarios.
- Extra Trees Classifier ofrece el mejor balance: Recall = 0.23, F1 = 0.29, Kappa = 0.12 y AUC competitivo de 0.572. Captura más desertores reales sin disparar excesivamente el costo de la campaña.
- Si la gerencia financiera establece un presupuesto limitado para la campaña, Random Forest (Recall = 0.19, Precision = 0.454) es la alternativa que reduce el desperdicio de incentivos.

Modelo	Recall	F1-Score	Veredicto
CatBoost / LightGBM / Extreme GB	0.1169	0.2094	No apto — detecta menos del 12% de desertores
Random Forest	0.1937	0.2715	Alternativa conservadora (presupuesto limitado)
Extra Trees Classifier (Recomendado)	0.2296	0.2935	Mejor balance Recall / costo de campaña
Decision Tree	0.3567	0.3438	Alto volumen de falsos positivos — costoso

Conclusión: el costo de entregar un mes gratis a un cliente que no se iba (Falso Positivo) es recuperable. La pérdida de un cliente que cancela sin intervención (Falso Negativo) es permanente. Esta asimetría justifica priorizar el Recall sobre la Precision en la selección del modelo.

4. Problemas de infraestructura a 10 millones de clientes diarios

Al escalar el sistema a análisis en tiempo real sobre 10 millones de clientes diarios en arquitectura cloud (AWS / Azure), los algoritmos de tipo ensemble presentan tres cuellos de botella críticos frente a los modelos lineales:

Cuello de botella	Algoritmos pesados (Random Forest / Ensembles)	Modelos simples (Logistic Regression / Ridge)
Memoria RAM	RF con 70 árboles sobre 200k registros requiere varios GB. Con 10M de registros en streaming, la huella supera las instancias estándar.	Modelos lineales: ecuación matricial de pocos MB. Ejecutable en instancias serverless de bajo costo.
Latencia de inferencia	Cada predicción atraviesa decenas de árboles. A 10M de eventos/día, la latencia acumulada puede superar los SLA del sistema CRM.	Inferencia = multiplicación matricial simple. Ejecutable en microsegundos como Lambda function.
Reentrenamiento	Requiere reentrenamiento completo periódico sin aprendizaje incremental nativo. Jobs batch costosos en clúster Spark o GPU.	Reentrenamiento rápido. Compatible con aprendizaje en línea (online learning) para actualización incremental.

5. ¿Justifica un 2% adicional de Accuracy multiplicar por diez el costo de servidores?

En la mayoría de los escenarios, no. La decisión debe estar respaldada por un análisis costo-beneficio explícito: si el ingreso recuperado por la mayor tasa de detección supera el costo incremental de la infraestructura, la

inversión es justificable. De lo contrario, la diferencia marginal en precisión no compensa el impacto en el presupuesto de TI.

Para telecomunicaciones con millones de clientes en tiempo real, la arquitectura recomendada desde la perspectiva de Sistemas de Información Gerencial es:

- Entrenar el modelo complejo (GBM / XGBoost) en un entorno offline con el poder computacional disponible.
- Exportar el modelo entrenado como archivo serializado ligero en formato ONNX o PMML.
- Desplegarlo en un microservicio de inferencia de baja latencia (contenedor Docker o Lambda function en AWS), separando el costo del entrenamiento del costo de la inferencia en producción.

Esta arquitectura permite capturar la calidad predictiva de los modelos ensemble sin incurrir en el costo computacional de reentrenarlos en cada ciclo de predicción en producción.

2 Parte: Predicción de Entregas Tardías en E-Commerce con H2O AutoML

1. Análisis de Arquitecturas

- El modelo que ocupó el primer lugar en el Leaderboard de H2O AutoML fue el GBM (Gradient Boosting Machine), con un AUC de 0.6147. Esta familia de algoritmos pertenece a los modelos de Árboles de Decisión en Ensamble.
-
- Los modelos de Árboles de Decisión superan a los modelos lineales (GLM) en este contexto por las siguientes razones:
- Las averías de máquinas no siguen patrones lineales: un sensor de torque alto, combinado con temperatura elevada, genera falla de forma abrupta, no gradual. Los árboles capturan estos umbrales críticos de forma natural.
- Los datos de sensores físicos (temperatura, torque, peso) presentan interacciones no lineales complejas que un modelo GLM simplemente no puede modelar.
- El GBM construye árboles secuenciales que corrigen los errores del árbol anterior, logrando alta precisión con datos ruidosos típicos de entornos industriales.

2. La Matriz de Confusión obtenida sobre los datos de prueba (29,902 envíos) fue la siguiente:

	Predijo A Tiempo (0)	Predijo TARDE (1)
Real A Tiempo (0)	845 Verdaderos Negativos	13,622 FALSOS POSITIVOS
Real TARDE (1)	366 FALSOS NEGATIVOS	15,069 Verdaderos Positivos

3. Falsos Positivos — El costo de la paranoia

El modelo generó 13,622 falsas alarmas (predijo retraso, pero el envío llegó a tiempo).

Concepto	Valor
Número de Falsos Positivos	13,622 alertas falsas
Costo por inspección innecesaria	\$150 USD
Costo total desperdiciado	\$2,043,300 USD

4. Falsos Negativos — El costo de la ceguera

El modelo dejó pasar 366 retrasos reales sin emitir ninguna alerta.

Concepto	Valor
Número de Falsos Negativos	366 fallas no detectadas
Costo por falla catastrófica	\$5,000 USD
Costo total de fallas no detectadas	\$1,830,000 USD

5. Veredicto de ROI

Escenario	Costo Total
CON el modelo (FP + FN)	\$2,043,300 + \$1,830,000 = \$3,873,300 USD
SIN el modelo (todas las fallas sin detectar)	15,435 fallas × \$5,000 = \$77,175,000 USD
AHORRO NETO con el modelo	\$73,301,700 USD (reducción del 95%)

CONCLUSIÓN: La implementación del modelo es ampliamente rentable. Aunque genera falsas alarmas, el costo de estas es marginal comparado con el costo de las fallas catastróficas que previene. El ROI justifica plenamente la inversión tecnológica.

6. Tensión de Métricas: Recall vs. Precision

Se debe priorizar el RECALL (Sensibilidad) por encima de la Precisión.

Justificación: En un entorno donde una falla no detectada implica riesgo físico real para el operario, es preferible generar falsas alarmas (inspecciones innecesarias de \$150) que dejar pasar una falla real (\$5,000 + riesgo de lesión). La seguridad ocupacional tiene prioridad absoluta sobre la eficiencia productiva.

Métrica	Favorece a	Costo del error
Precision alta	Jefe de Producción	Fallas no detectadas → riesgo físico

Recall alto ✓ ELEGIDA	Jefe de Seguridad	Inspecciones innecesarias → \$150
--------------------------	-------------------	-----------------------------------

Un operario lesionado genera consecuencias legales, humanas y reputacionales que ningún indicador financiero puede compensar. Por tanto, se configura el sistema para maximizar el Recall.

6. Intervención en el Piso de Planta

Según el gráfico de Variable Importance del modelo GBM (H2O Gradient Boosting Machine), los dos parámetros físicos que más detonan los retrasos son:

Posición	Variable	Descripción	Nivel de Importancia
#1	weight_in_gms	Peso del paquete en gramos	MUY ALTO (barra más larga)
#2	discount_offered	Descuento ofrecido al cliente	ALTO (segunda barra)

Estos dos factores explican la mayor parte de las predicciones del modelo. Los paquetes pesados (>4,500 g) con descuentos altos (>10%) concentran la mayor probabilidad de retraso.

7. Nueva Regla de Operación — Turno de Mañana

REGLA OPERATIVA N° 01-2026: A partir de hoy, todo pedido con peso superior a 4,500 gramos Y descuento mayor al 10% debe ser marcado automáticamente como PRIORITARIO en el sistema de despacho y asignado a transporte aéreo o ruta express antes de salir del almacén. El operario de turno es responsable de verificar esta condición antes del cierre de cada lote.

Link Looker Studio:

<https://datastudio.google.com/reporting/15fa8194-6ea2-4a82-9747-c8904eadf94d>

LinkColab1:<https://colab.research.google.com/drive/1SgKIMbAVQmSzM6InEFUXm1EUJ4tlisjr?usp=sharing>

LinkColab2:https://colab.research.google.com/drive/1Mlu7CzpsfWUCwrhgyQOVwJerxhW_WBbPk?usp=sharing